

Informe de Proyecto

ClimaXtreme: análisis climático y modelado de eventos extremos

Richard Alejandro Matos Arderí
Eveliz Espinaco Milián

Universidad de La Habana,
Facultad de Matemática y Computación

14 de diciembre de 2025



Resumen: Este informe presenta ClimaXtreme, una herramienta para el análisis climático y el modelado de eventos extremos sobre datos a gran escala con Hadoop y PySpark. Se implementa una canalización distribuida para la ingesta, limpieza y enriquecimiento de datos; agregaciones temporales y espaciales; y análisis estadístico, incluyendo teoría de valores extremos. Se desarrollan modelos predictivos y visualizaciones para detectar tendencias, anomalías y riesgos, priorizando calidad de datos, trazabilidad y reproducibilidad en entornos Big Data.

Índice

1	Dataset Seleccionado	4
1.1	Nombre, Fuente y Formato	4
1.2	Variables Estadísticas	4
2	Justificación del Dataset	5
2.1	Volumen	5
2.2	Características	5
2.3	Pertinencia	6
3	Arquitectura del Sistema	6
3.1	Visión General	6
3.2	Diagrama de Arquitectura	6
3.3	Componentes del Sistema	8
3.3.1	Capa de Almacenamiento: HDFS	8
3.3.2	Capa de Procesamiento: PySpark	8
3.3.3	Capa de Análisis: Archivos Parquet	9
3.3.4	Capa de Visualización: Streamlit Dashboard	9
3.4	Enfoque de Procesamiento	10
3.5	Infraestructura Docker	11
4	Metodología de Procesamiento	11
4.1	Pipeline de Procesamiento	11
4.1.1	1. Ingesta de Datos	11
4.1.2	2. Limpieza de Datos	12
4.1.3	3. Agregaciones Temporales	12
4.1.4	4. Agregaciones Espaciales	12
4.1.5	5. Análisis Estadístico	12
4.1.6	6. Detección de Anomalías	12
4.2	Modelos de Machine Learning	13
4.2.1	Modelos Base (BaselineModel)	13
4.2.2	Modelo Ensemble (ClimatePredictor)	13
4.2.3	Predictor de Intensidad (IntensityPredictor)	14
4.2.4	Métricas de Evaluación	14
4.3	Generación de Datos Sintéticos	14
4.3.1	Modelo de Temperatura Horaria	15
4.3.2	Modelo de Precipitación	15
4.3.3	Tracking de Tormentas	15
5	Análisis de Resultados	15
5.1	Tendencias de Temperatura Global	15
5.2	Patrones Regionales	16
5.3	Eventos Extremos Detectados	16
5.4	Agregaciones Generadas	16
5.5	Rendimiento de Modelos Predictivos	16

6	Análisis de Rendimiento del Clúster	17
6.1	Configuración del Clúster	17
6.2	Consumo de Recursos	17
6.3	Tiempos de Ejecución	18
6.4	Optimizaciones Aplicadas	18
6.5	Streaming con Apache Kafka	18
6.6	Cuellos de Botella Identificados	18
7	Conclusiones	19
7.1	Logros Alcanzados	19
7.2	Limitaciones del Sistema	19
7.3	Trabajo Futuro	20
8	Referencias	20

1. Dataset Seleccionado

En esta sección se describe el conjunto de datos elegido para el desarrollo del proyecto.

1.1. Nombre, Fuente y Formato

- **Nombre:** Cambio climático: datos de temperatura de la superficie terrestre
- **Fuente:** <https://www.kaggle.com/datasets/berkeleyearth/climate-change-earth-surface-temperature-data>
- **Formato:** CSV

1.2. Variables Estadísticas

A continuación, se describen las variables incluidas en el dataset, detallando su significado, los valores que pueden tomar, y su clasificación correspondiente.

- **Fecha:** Indica el año de la medición. Los valores comienzan en 1750 para la temperatura media de la tierra y en 1850 para las temperaturas máximas y mínimas, así como para las temperaturas globales de océanos y tierra.
Valores: Años (1750 en adelante).
Tipo: Variable cuantitativa, escala ordinal.
- **País:** País donde se realizó la medición.
Valores: Nombres de países (por ejemplo, España, México, Argentina).
Tipo: Variable cualitativa, escala nominal.
- **Ciudad:** Ciudad específica de la estación meteorológica.
Valores: Nombres de ciudades (por ejemplo, Madrid, Buenos Aires).
Tipo: Variable cualitativa, escala nominal.
- **Latitud:** Coordenada geográfica norte-sur de la estación.
Valores: Números reales en grados decimales (por ejemplo, 40.4168).
Tipo: Variable cuantitativa, escala de razón.
- **Longitud:** Coordenada geográfica este-oeste de la estación.
Valores: Números reales en grados decimales (por ejemplo, -3.7038).
Tipo: Variable cuantitativa, escala de razón.
- **Temperatura media del terreno:** Representa la temperatura media global de la superficie terrestre, expresada en grados Celsius.
Valores: Números reales (por ejemplo, 13.5°C).
Tipo: Variable cuantitativa, escala de razón.
- **Incertidumbre de la temperatura media del terreno:** Intervalo de confianza del 95 % alrededor del promedio de la temperatura media del terreno.
Valores: Números reales positivos (por ejemplo, 0.12°C).
Tipo: Variable cuantitativa, escala de razón.

2. Justificación del Dataset

El dataset seleccionado contiene registros históricos de temperatura de la superficie terrestre, recolectados a lo largo de varias décadas mediante distintos métodos e instrumentos. Su uso está justificado por la complejidad inherente a los datos, que exige una gran cantidad de limpieza, normalización y procesamiento para poder extraer conclusiones válidas sobre las tendencias climáticas a largo plazo. Los primeros registros fueron obtenidos por técnicos que utilizaban termómetros de mercurio, donde incluso pequeñas variaciones en la hora de la medición podían alterar significativamente los valores registrados. Posteriormente, en la década de 1940, la construcción de aeropuertos obligó al traslado físico de muchas estaciones meteorológicas, introduciendo discontinuidades espaciales en las series de datos. Más adelante, en los años 80, se incorporaron termómetros electrónicos, los cuales presentan un sesgo sistemático de enfriamiento que debe ser corregido para garantizar la coherencia del análisis.

Este contexto histórico y técnico convierte al dataset en un excelente candidato para evaluar los conocimientos adquiridos en la asignatura de Procesamiento de Grandes Volúmenes de Datos. A pesar de que el volumen original es relativamente pequeño, la riqueza estructural, la heterogeneidad temporal y la presencia de sesgos lo hacen ideal para simular escenarios reales de Big Data, donde la calidad y la gobernanza de los datos son tan importantes como la cantidad.

2.1. Volumen

El dataset cuenta con aproximadamente 8.6 millones de registros, lo que lo convierte en un ejemplo representativo de escenarios reales de Big Data. Este volumen masivo permite aplicar técnicas avanzadas de procesamiento distribuido, como particionamiento, replicación y procesamiento paralelo, utilizando herramientas como Hadoop o Spark. La gran cantidad de datos facilita la segmentación por décadas, estaciones meteorológicas, países, o tipo de sensor, permitiendo diseñar esquemas de particionamiento que reflejan los principios de escalabilidad horizontal. Además, el tamaño del dataset posibilita la realización de análisis estadísticos robustos, la detección de patrones complejos y la generación de modelos predictivos con mayor precisión. La integración con fuentes externas (como altitud, ubicación geográfica, eventos históricos) y la generación de datos derivados amplían aún más las posibilidades de exploración y simulación en entornos de procesamiento masivo.

2.2. Características

Los atributos presentes en el dataset incluyen fecha de medición, ubicación geográfica, tipo de instrumento utilizado, temperatura registrada, y metadatos asociados a la estación meteorológica. La temporalidad es extensa, abarcando desde principios del siglo XX hasta la actualidad, lo que permite estudiar fenómenos de largo plazo como el cambio climático, la variabilidad estacional, y los efectos de urbanización. El dataset no está etiquetado en el sentido clásico de aprendizaje supervisado, pero permite generar etiquetas derivadas (por ejemplo, anomalías térmicas, zonas de cambio abrupto, o eventos extremos) mediante procesamiento. El nivel de ruido es alto: hay inconsistencias en las unidades, valores faltantes, duplicados, y sesgos sistemáticos que deben ser corregidos.

Esta situación obliga a aplicar técnicas de limpieza, imputación, normalización y reconciliación de fuentes, lo cual es central en el estudio de grandes volúmenes de datos.

2.3. Pertinencia

El dataset se relaciona directamente con los objetivos de la asignatura, ya que permite aplicar de forma integrada todos los conceptos clave: ingestión de datos desde múltiples fuentes, limpieza intensiva, transformación distribuida, almacenamiento optimizado, y análisis escalable. Además, su temática —las tendencias climáticas— es de alta relevancia social y científica, lo que motiva el trabajo y permite conectar la teoría con problemas reales. El proyecto puede incluir la simulación de un Data Lake con zonas raw, curated y analytics; el uso de herramientas como Apache Spark para agregaciones por década; y la visualización de resultados mediante dashboards interactivos. En conjunto, el dataset ofrece una oportunidad única para evaluar competencias técnicas, analíticas y metodológicas en un entorno controlado pero representativo de los desafíos del procesamiento de grandes volúmenes de datos.


3. Arquitectura del Sistema

Esta sección describe la arquitectura completa del sistema ClimaXtreme, incluyendo los componentes de infraestructura, procesamiento y visualización.

3.1. Visión General

El sistema implementa una arquitectura híbrida que combina procesamiento **batch** para el análisis histórico del dataset completo y capacidades de **streaming simulado** para demostrar análisis en tiempo real. La arquitectura se despliega completamente en contenedores Docker, garantizando reproducibilidad y portabilidad.

3.2. Diagrama de Arquitectura



CAPA DE ALMACENAMIENTO (HDFS)		
+-----+	+-----+	+-----+
NameNode	DataNode 1	DataNode 2
(Metadatos)	(Datos)	(Datos)
:9870, :9000		
+-----+	+-----+	+-----+
		+-----+
		DataNode 3
Factor de Replicación: 3		+-----+
+-----+		
v		
+-----+		
CAPA DE PROCESAMIENTO		
+-----+	+-----+	
PySpark	Apache Kafka	
- Limpieza	- Zookeeper :2181	
- Agregaciones	- Broker :9092	
- ML Models	- 5 Topics	
:4040 (Spark UI)	- weather, alerts	
+-----+	- storms, progress	
	+-----+	
+-----+		
v		
+-----+		
CAPA DE ANÁLISIS Y RESULTADOS		
+-----+	+-----+	+-----+
anomalies	monthly	regional
8.2M reg	.parquet	.parquet
+-----+	+-----+	+-----+
+-----+	+-----+	+-----+
yearly	seasonal	continental
.parquet	.parquet	.parquet
+-----+	+-----+	+-----+
+ 6 archivos adicionales (EDA, climatology, extremes)		
+-----+		
v		
+-----+		
CAPA DE VISUALIZACIÓN		
+-----+		
STREAMLIT DASHBOARD (:8501)		
+-----+	+-----+	+-----+
BATCH	STREAMING	HYBRID
Temporal	Storm	Historical

			Anomalías			Tracking			Comparison								
			Seasonal			Alerts			EDA Valid.								
			Extreme			TimeSeries			Intensity								
			Heatmaps			Forecast			Prediction								
			+-----+				+-----+				+-----+						
			17 páginas interactivas de análisis														
		+-----+															
	+-----+																
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	
+-----+																	

3.3. Componentes del Sistema

3.3.1. Capa de Almacenamiento: HDFS

El sistema de archivos distribuido Hadoop (HDFS) proporciona almacenamiento tolerante a fallos para los datos climáticos.

- **NameNode:** Nodo maestro que gestiona los metadatos del sistema de archivos, incluyendo la estructura de directorios y la ubicación de los bloques de datos. Expone la interfaz web en el puerto 9870 y la API HDFS en el puerto 9000.
- **DataNodes (x3):** Tres nodos de trabajo que almacenan los bloques de datos reales. Con un factor de replicación de 3, cada bloque se replica en los tres nodos, garantizando alta disponibilidad y tolerancia a fallos.
- **Estructura de directorios HDFS:**
 - /data/raw/: Datos originales en formato CSV
 - /data/processed/: Archivos Parquet procesados
 - /data/synthetic/: Datos sintéticos generados

3.3.2. Capa de Procesamiento: PySpark

Apache Spark se utiliza para el procesamiento distribuido de los datos climáticos.

- **Processor Container:** Contenedor principal que ejecuta los jobs de Spark para limpieza, transformación y agregación de datos. Incluye:
 - Limpieza de datos (eliminación de nulos, normalización de coordenadas)
 - Agregaciones temporales (mensual, anual, estacional)
 - Agregaciones espaciales (regional, continental)
 - Análisis estadístico (correlaciones, estadísticas descriptivas)
 - Detección de anomalías y eventos extremos

- **Synthetic Generator:** Servicio opcional para generar datos sintéticos que complementan el dataset original, permitiendo simulaciones de streaming y eventos extremos.
- **Spark UI (puerto 4040):** Interfaz web para monitorear la ejecución de jobs, stages, tasks y métricas de rendimiento.

3.3.3. Capa de Análisis: Archivos Parquet

El pipeline genera 12 archivos Parquet optimizados para consultas analíticas:

Archivo	Descripción	Registros
anomalies.parquet	Desviaciones de temperatura (z-score)	8,218,457
country.parquet	Agregaciones por país	31,395
regional.parquet	Agregaciones por 16 regiones	4,327
monthly.parquet	Agregaciones mensuales por ciudad	3,143
continental.parquet	Agregaciones por 6 continentes	1,411
yearly.parquet	Agregaciones anuales por ciudad	263
climatology.parquet	Valores climatológicos de referencia	12
seasonal.parquet	Agregaciones por estación	4
extreme_thresholds.parquet	Umbrales P10, P90	3
correlation_matrix.parquet	Matriz de Pearson	4
chi_square_tests.parquet	Tests de independencia	4
descriptive_stats.parquet	11 métricas estadísticas	2

Cuadro 1: Archivos Parquet generados por el pipeline (datos reales)

3.3.4. Capa de Visualización: Streamlit Dashboard

Dashboard interactivo con 17 páginas de análisis organizadas en tres categorías:
Análisis Batch (datos históricos de HDFS):

1. **Temporal Analysis:** Tendencias de temperatura a lo largo del tiempo (1751-2013)
2. **Anomalies:** Detección y visualización de anomalías térmicas
3. **Seasonal Analysis:** Patrones estacionales por hemisferio
4. **Extreme Events:** Identificación de eventos extremos ($>2\sigma$)
5. **Country Analysis:** Análisis detallado por país
6. **Continental Analysis:** Comparativas entre continentes
7. **Statistical Analysis:** Tests estadísticos y correlaciones
8. **Climate Heatmaps:** Mapas de calor geográficos

Streaming en Tiempo Real (Apache Kafka):

9. **Streaming Hub:** Control central del productor Kafka
10. **Live Streaming:** Visualización de datos en tiempo real
11. **Storm Tracking:** Seguimiento de tormentas con trayectorias
12. **Active Alerts:** Monitor de alertas climáticas activas

Análisis Híbrido (Kafka + HDFS):

13. **Intensity Prediction:** Predicción de intensidad basada en anomalías
14. **Weather TimeSeries:** Series temporales con comparación histórica
15. **Streaming Forecast:** Pronóstico basado en datos streaming
16. **EDA Validation:** Validación de datos streaming vs históricos
17. **Historical Comparison:** Comparación streaming vs HDFS

3.4. Enfoque de Procesamiento

El sistema implementa un enfoque híbrido con tres modos de operación:

- **Batch Processing:** Procesamiento del dataset histórico completo (8.2M registros) mediante jobs de Spark. Este modo genera las agregaciones y análisis que alimentan las páginas de visualización histórica del dashboard.
- **Streaming en Tiempo Real (Apache Kafka):** Sistema de mensajería distribuida con 5 topics especializados:
 - **weather_data:** Datos meteorológicos sintéticos generados cada 100ms
 - **weather_alerts:** Alertas de eventos extremos
 - **storm_tracking:** Posiciones y trayectorias de tormentas simuladas
 - **weather_predictions:** Predicciones basadas en modelos
 - **generator_progress:** Estadísticas del generador
- **Análisis Híbrido:** Combinación de datos streaming con datos históricos de HDFS para comparaciones en tiempo real, validación de anomalías y pronósticos contextualizados.

3.5. Infraestructura Docker

Toda la infraestructura se despliega mediante Docker Compose con 8 contenedores, facilitando la reproducibilidad:

```
docker-compose.yml
+--- namenode (bde2020/hadoop-namenode)
+--- datanode1 (bde2020/hadoop-datanode)
+--- datanode2 (bde2020/hadoop-datanode)
+--- datanode3 (bde2020/hadoop-datanode)
+--- processor (custom: Dockerfile.processor)
+--- dashboard (custom: Dockerfile.processor)
+--- kafka (confluentinc/cp-kafka)
+--- zookeeper (confluentinc/cp-zookeeper)
+--- synthetic-generator (profile: synthetic)
```

Red: Todos los contenedores se comunican a través de una red bridge llamada **hdfs**.

Volúmenes: Se utilizan volúmenes Docker para persistir los datos de HDFS y los datos sintéticos.

Puertos expuestos:

- 9870: HDFS NameNode Web UI
- 9864-9866: DataNodes Web UI
- 4040: Spark Web UI
- 8501: Streamlit Dashboard
- 9092: Apache Kafka Broker
- 2181: Zookeeper

4. Metodología de Procesamiento

Esta sección detalla las transformaciones y algoritmos aplicados a los datos climáticos.

4.1. Pipeline de Procesamiento

El pipeline de procesamiento sigue las siguientes etapas:

4.1.1. 1. Ingesta de Datos

- Lectura del archivo CSV desde HDFS usando Spark
- Schema inferido automáticamente con validación de tipos
- Particionamiento inicial basado en el tamaño del archivo

4.1.2. 2. Limpieza de Datos

Las transformaciones de limpieza incluyen:

- **Eliminación de nulos:** Registros sin temperatura se eliminan
- **Normalización de coordenadas:** Conversión de formato “57.05N” a valores decimales (57.05)
- **Extracción temporal:** Derivación de año, mes, día de semana desde la fecha
- **Validación de rangos:** Temperaturas fuera de $[-90^{\circ}\text{C}, 60^{\circ}\text{C}]$ se marcan como outliers
- **Deduplicación:** Eliminación de registros duplicados por ciudad y fecha

4.1.3. 3. Agregaciones Temporales

- **Mensual:** Promedio, mínimo, máximo y desviación estándar por ciudad/mes
- **Anual:** Agregación de métricas mensuales a nivel anual
- **Estacional:** Agrupación por estaciones (DJF, MAM, JJA, SON)
- **Climatología:** Promedios históricos de referencia (1961-1990)

4.1.4. 4. Agregaciones Espaciales

- **Regional:** Clasificación en 16 regiones geográficas basada en latitud/longitud
- **Continental:** Agregación por 7 continentes

4.1.5. 5. Análisis Estadístico

- **Matriz de correlación de Pearson:** Entre variables numéricas (año, temperatura promedio, mínima, máxima, rango)
- **Estadísticas descriptivas:** Media, mediana, desviación estándar, cuartiles, asimetría, curtosis
- **Pruebas Chi-cuadrado:** Tests de independencia entre variables categóricas (continente, estación, período vs. categoría de temperatura)

4.1.6. 6. Detección de Anomalías

Las anomalías se calculan como desviaciones respecto a la climatología de referencia:

$$\text{Anomalía} = T_{\text{observada}} - T_{\text{climatología}} \quad (1)$$

Se clasifican según umbrales:

- $|\text{Anomalía}| < 1\sigma$: Normal
- $1\sigma \leq |\text{Anomalía}| < 2\sigma$: Moderada
- $|\text{Anomalía}| \geq 2\sigma$: Extrema

4.2. Modelos de Machine Learning

El sistema implementa una arquitectura de Machine Learning por capas, con modelos base individuales que se combinan en un ensemble para mejorar la precisión de las predicciones.

4.2.1. Modelos Base (BaselineModel)

La clase `BaselineModel` implementa cinco tipos de modelos de regresión:

Modelo	Hiperparámetros	Características
Linear Regression	-	Modelo base simple, rápido de entrenar
Ridge Regression	$\alpha = 1,0$	Regularización L2 para evitar overfitting
Lasso Regression	$\alpha = 1,0$	Regularización L1, selección automática de features
Random Forest	<code>n_estimators=100, n_jobs=-1</code>	Ensemble de árboles, robusto ante outliers
Gradient Boosting	<code>n_estimators=100</code>	Boosting secuencial, alta precisión

Cuadro 2: Modelos base implementados en el sistema

Features utilizadas:

- `year`: Año de la medición
- `month`: Mes (1-12)
- `year_normalized`: Año normalizado al rango [0,1]
- `month_sin`, `month_cos`: Codificación cíclica del mes
- Features adicionales derivadas del dataset

4.2.2. Modelo Ensemble (ClimatePredictor)

La clase `ClimatePredictor` combina múltiples modelos base usando `VotingRegressor` de `scikit-learn`:

```
VotingRegressor(estimators=[
    ('linear', LinearRegression()),
    ('ridge', Ridge(alpha=1.0)),
    ('random_forest', RandomForestRegressor(n_estimators=100))
])
```

Características del ensemble:

- Combinación por votación promediada de predicciones

- Time Series Cross-Validation con 5 splits para evaluación
- Cuantificación de incertidumbre mediante dispersión de predicciones individuales
- Persistencia de modelos con joblib

4.2.3. Predictor de Intensidad (IntensityPredictor)

Modelo especializado para predecir la intensidad de eventos extremos en una escala de 0 a 10.

Features del predictor de intensidad:

- `temperature_hourly`: Temperatura horaria (°C)
- `rain_mm`: Precipitación (mm)
- `wind_speed_kmh`: Velocidad del viento (km/h)
- `humidity_pct`: Humedad relativa (%)
- `pressure_hpa`: Presión atmosférica (hPa)
- `month`, `hour`: Variables temporales
- `latitude_numeric`: Latitud numérica
- Codificación one-hot de zona climática y tipo de evento

Configuración del modelo:

- Random Forest: `max_depth=15`, `min_samples_split=5`, `min_samples_leaf=2`
- Gradient Boosting: `max_depth=8`, `learning_rate=0.1`
- Ensemble: VotingRegressor con RF + GB

4.2.4. Métricas de Evaluación

Los modelos se evalúan con las siguientes métricas:

Métrica	Fórmula	Interpretación
RMSE	$\sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}$	Error cuadrático medio (misma unidad que y)
MAE	$\frac{1}{n} \sum_{i=1}^n y_i - \hat{y}_i $	Error absoluto medio
R ²	$1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$	Varianza explicada (0 a 1)

Cuadro 3: Métricas de evaluación de modelos

4.3. Generación de Datos Sintéticos

Para las visualizaciones avanzadas (tormentas, alertas, streaming), se generan datos sintéticos:

4.3.1. Modelo de Temperatura Horaria

$$T_{horaria}(h) = T_{media} + A_{diurna} \cdot \sin\left(\frac{2\pi(h - h_{max})}{24}\right) + \epsilon \quad (2)$$

Donde:

- T_{media} : Temperatura media diaria del dataset original
- A_{diurna} : Amplitud diurna (función de latitud y estación)
- h_{max} : Hora de temperatura máxima (14:00)
- $\epsilon \sim N(0, \sigma^2)$: Ruido gaussiano

4.3.2. Modelo de Precipitación

Cadena de Markov de orden 1 para estados wet/dry, con cantidad de lluvia modelada mediante distribución Gamma.

4.3.3. Tracking de Tormentas

Simulación de trayectorias de tormentas con:

- Posición inicial aleatoria en zonas de formación
- Movimiento basado en patrones climáticos típicos
- Intensificación/debilitamiento según temperatura del océano

5. Análisis de Resultados

Esta sección presenta los resultados obtenidos del análisis climático tras la ejecución del pipeline completo sobre 8,218,457 registros históricos.

5.1. Tendencias de Temperatura Global

El análisis del dataset histórico (1751-2013) revela patrones significativos en la evolución de las temperaturas globales:

- **Período de registro:** 263 años de datos continuos
- **Cobertura geográfica:** 3,463 ciudades únicas en 6 continentes
- **Volumen total:** 8,218,457 registros de temperatura

La distribución temporal muestra un incremento progresivo en la densidad de mediciones a partir de 1850, coincidiendo con la expansión de redes meteorológicas globales.

Continente	Registros	Porcentaje
Asia	3,504,046	42.64 %
Europa	2,043,725	24.87 %
América del Norte	1,074,434	13.08 %
América del Sur	808,205	9.83 %
África	740,827	9.02 %
Oceanía	47,220	0.57 %
Total	8,218,457	100.00 %

Cuadro 4: Distribución de registros por continente

5.2. Patrones Regionales

El análisis por continente revela distribuciones diferenciadas:

5.3. Eventos Extremos Detectados

El sistema de detección de anomalías identificó eventos significativos basándose en desviaciones estándar respecto a la climatología de referencia:

- **Total anomalías detectadas:** 70,005 eventos
- **Tasa de anomalías:** 0.85 % del total de registros
- **Criterio:** Desviación $\geq 2\sigma$ respecto a la media climatológica

Las anomalías se distribuyen tanto en eventos de calentamiento extremo como de enfriamiento anómalo, con mayor concentración en latitudes altas donde la variabilidad climática es naturalmente mayor.

5.4. Agregaciones Generadas

El pipeline generó múltiples niveles de agregación almacenados en formato Parquet:

5.5. Rendimiento de Modelos Predictivos

El modelo de predicción de intensidad utiliza un enfoque heurístico basado en múltiples variables:

- **Z-Score de temperatura:** Peso del 60 % en la predicción
- **Factor estacional:** Peso del 20 % (mayor intensidad en meses extremos)
- **Incertidumbre histórica:** Peso del 20 % (basado en desviación estándar)

Este modelo permite estimar la intensidad de eventos extremos en una escala de 0 a 10, facilitando la generación de alertas en el sistema de streaming.

Archivo Parquet	Registros
anomalies.parquet	8,218,457
country_analysis.parquet	31,395
regional_analysis.parquet	4,327
monthly_aggregation.parquet	3,143
continental_analysis.parquet	1,411
yearly_aggregation.parquet	263
temperature_stats.parquet	28
seasonal_aggregation.parquet	28
hemispheric_trends.parquet	4

Cuadro 5: Archivos Parquet generados por el pipeline

6. Análisis de Rendimiento del Clúster

Esta sección documenta el rendimiento observado del clúster HDFS durante la ejecución del pipeline de procesamiento.

6.1. Configuración del Clúster

Componente	Configuración
NameNode	1 instancia (puerto 9870)
DataNodes	3 instancias con factor de replicación 3
Tamaño de bloque HDFS	128 MB
Memoria Spark Driver	2 GB
Memoria Spark Executor	2 GB
Apache Kafka	1 broker con Zookeeper

Cuadro 6: Configuración del clúster Hadoop/Spark

6.2. Consumo de Recursos

Durante la ejecución del pipeline se observaron los siguientes patrones de uso de recursos:

- **CPU:** Utilización variable entre 40-90 % durante operaciones de transformación intensivas
- **Memoria:** Consumo estable del 60-80 % de la memoria asignada a Spark
- **Red:** Picos de tráfico durante operaciones de shuffle entre DataNodes
- **Disco:** Mayor actividad durante escritura de archivos Parquet

6.3. Tiempos de Ejecución

Operación	Tiempo (s)	Registros	Throughput (reg/s)
Lectura CSV inicial	45	8,599,212	191,093
Limpieza y validación	30	8,218,457	273,949
Agregación mensual	25	3,143	126
Agregación anual	15	263	18
Detección de anomalías	40	70,005	1,750
Análisis por país	35	31,395	897
Análisis continental	20	1,411	71
Escritura Parquet	50	8,218,457	164,369
Total Pipeline	~260	-	-

Cuadro 7: Tiempos de ejecución del pipeline de procesamiento

6.4. Optimizaciones Aplicadas

Se implementaron las siguientes optimizaciones para mejorar el rendimiento:

1. **Formato Parquet:** Almacenamiento columnar con compresión Snappy, reduciendo el tamaño en disco un 70 % respecto al CSV original.
2. **Particionamiento:** Los datos se particionan por continente y año para optimizar consultas filtradas.
3. **Caching estratégico:** DataFrames intermedios frecuentemente accedidos se cachean en memoria.
4. **Broadcast joins:** Tablas de lookup pequeñas (países, continentes) se distribuyen a todos los ejecutores.
5. **Persistencia en HDFS:** Factor de replicación 3 para alta disponibilidad sin impacto significativo en rendimiento.

6.5. Streaming con Apache Kafka

El sistema de streaming procesa datos en tiempo real con las siguientes características:

6.6. Cuellos de Botella Identificados

Durante el análisis se identificaron las siguientes limitaciones:

- **Operaciones de shuffle:** Las agregaciones por múltiples dimensiones generan shuffles costosos entre nodos.
- **Memoria del driver:** Visualizaciones que requieren coleccionar datos al driver pueden causar OOM en datasets muy grandes.

Métrica	Valor
Topics Kafka	5 (weather, alerts, storms, predictions, progress)
Ciudades monitoreadas	3,463 (cargadas dinámicamente desde HDFS)
Frecuencia de actualización	100ms - 1000ms configurable
Latencia productor-consumidor	<50ms

Cuadro 8: Métricas del sistema de streaming Kafka

- **Serialización:** La conversión entre Spark DataFrames y Pandas para visualización añade latencia.
- **Conexión HDFS desde contenedor:** La detección del entorno (Docker vs local) requiere lógica adicional para seleccionar el método de acceso apropiado.

7. Conclusiones

Este proyecto ha demostrado la viabilidad de implementar un sistema completo de análisis climático utilizando tecnologías de Big Data en un entorno containerizado.

7.1. Logros Alcanzados

1. **Pipeline de procesamiento escalable:** Se procesaron exitosamente 8,218,457 registros climáticos históricos (1751-2013) utilizando Apache Spark sobre HDFS, generando 12 archivos Parquet optimizados para consultas analíticas.
2. **Arquitectura híbrida batch/streaming:** Integración de procesamiento batch (HDFS/Spark) con streaming en tiempo real (Apache Kafka) permitiendo análisis tanto de datos históricos como de flujos continuos.
3. **Detección de anomalías:** Sistema capaz de identificar 70,005 eventos climáticos extremos (0.85 % del dataset) basándose en desviaciones estadísticas respecto a la climatología de referencia.
4. **Dashboard interactivo:** Interfaz web con 17 páginas de visualización organizadas en categorías (Batch, Streaming, Híbrido), proporcionando análisis desde múltiples perspectivas.
5. **Cobertura global:** Análisis de 3,463 ciudades distribuidas en 6 continentes, con énfasis en Asia (42.64 %) y Europa (24.87 %).

7.2. Limitaciones del Sistema

- El dataset original contiene gaps temporales y cobertura geográfica desigual, especialmente en períodos anteriores a 1850.
- Los modelos predictivos utilizan enfoques heurísticos; modelos de deep learning podrían mejorar la precisión.

7.3. Trabajo Futuro

1. Implementación de modelos LSTM para predicción de series temporales climáticas
2. Integración con fuentes de datos meteorológicos en tiempo real (APIs públicas)
3. Ampliación del dashboard con análisis de correlación clima-eventos socioeconómicos
4. Despliegue en plataforma cloud (AWS EMR, Google Dataproc) para evaluación de escalabilidad
5. Implementación de Apache Flink para procesamiento de eventos complejos (CEP)

8. Referencias

1. Berkeley Earth. (2017). Climate Change: Earth Surface Temperature Data. Kaggle. <https://www.kaggle.com/datasets/berkeleyearth/climate-change-earth-surface-tem>
2. Apache Spark Documentation. <https://spark.apache.org/docs/latest/>
3. Hadoop HDFS Architecture Guide. <https://hadoop.apache.org/docs/stable/hadoop-project-dist/hadoop-hdfs/HdfsDesign.html>
4. Apache Kafka Documentation. <https://kafka.apache.org/documentation/>
5. Streamlit Documentation. <https://docs.streamlit.io/>
6. Docker Documentation. <https://docs.docker.com/>
7. Apache Parquet Format. <https://parquet.apache.org/docs/>